

# BIM – Übung 2

## Aufgabe 1

### Aufgabe 1.1

```
import java.io.*;
import java.util.ArrayList;
import java.util.HashSet;
import java.util.List;
import java.util.Set;

/**
 * Klasse, welche das Greedy-Superstring-Verfahren simuliert
 */
public class GreedySuperString {
    //<editor-fold desc="Felder">
    private static String fragment1;
    private static String fragment2;
    private static int besteDeckung;
    private static int indexBesteDeckung;
    //</editor-fold>

    /**
     * Hauptprogramm.
     *
     * @param args Kommandozeilen-Argumente
     */
    public static void main(String[] args) throws IOException{
        File dir = new File(".");

        File unbekannterTextDatei = new File(dir.getCanonicalPath() +
            File.separator + "src" + File.separator + "unbekannterText.txt");
        List<String> unbekannterText = ladeFragmente(unbekannterTextDatei);
        List<String> unbekannterTextTeilstringfrei =
            entferneTeilstrings(unbekannterText);
        String superStringUnbekannterText =
            GreedySuperstring(unbekannterTextTeilstringfrei);
        ausgabedesSuperstrings(superStringUnbekannterText);

        File unbekanteDNA1Datei = new File(dir.getCanonicalPath() + File.separator
            + "src" + File.separator + "DNAFragment1.txt");
        List<String> unbekanteDNA1 = ladeFragmente(unbekanteDNA1Datei);
        List<String> unbekanteDNA1Teilstringfrei =
            entferneTeilstrings(unbekanteDNA1);
        String superStringUnbekanteDNA1 =
            GreedySuperstring(unbekanteDNA1Teilstringfrei);
        ausgabedesSuperstrings(superStringUnbekanteDNA1);

        File unbekanteDNA2Datei = new File(dir.getCanonicalPath() + File.separator
```

```

        + "src" + File.separator + "DNAFragmente2.txt");
List<String> unbekannteDNA2 = ladeFragmente(unbekannteDNA2Datei);
List<String> unbekannteDNA2Teilstringfrei =
    entferneTeilstrings(unbekannteDNA2);
String superStringUnbekannteDNA2 =
    GreedySuperstring(unbekannteDNA2Teilstringfrei);
ausgabedesSuperstrings(superStringUnbekannteDNA2);

File unbekannteDNA3Datei = new File(dir.getCanonicalPath() + File.separator
    + "src" + File.separator + "DNAFragmente3.txt");
List<String> unbekannteDNA3 = ladeFragmente(unbekannteDNA3Datei);
List<String> unbekannteDNA3Teilstringfrei =
    entferneTeilstrings(unbekannteDNA3);
String superStringUnbekannteDNA3 =
    GreedySuperstring(unbekannteDNA3Teilstringfrei);
ausgabedesSuperstrings(superStringUnbekannteDNA3);
}

//<editor-fold desc="Laden und Verarbeitung der Fragmente">
/**
 * Liest eine Datei Zeile fuer Zeile ein.
 *
 * @param datei Datei, welche eingelesen werden soll
 * @throws IOException IOException, welche geworfen werden kann
 */
private static List<String> ladeFragmente(File datei) throws IOException{
    List<String> fragmente = new ArrayList<String>();

    BufferedReader br = new BufferedReader(new FileReader(datei));

    String zeile = null;

    //Liest die Datei Zeile fuer Zeile ein
    while((zeile = br.readLine()) != null) {
        fragmente.add(zeile);
    }

    return fragmente;
}

/**
 * Entfernt alle Teilstrings aus der Fragmentliste
 *
 * @param fragmentListe Fragmentliste, aus welcher die Teilstrings entfernt
    werden muessen
 * @return Liste mit Teilstring-freien Fragmenten
 */
private static List<String> entferneTeilstrings(List<String> fragmentListe){
    List<String> teilstringFreieListe = new ArrayList<String>();

    Set<String> uniqueFragmentListe = new HashSet<String>(fragmentListe);

    for(String fragment : uniqueFragmentListe){
        // Nur wenn das Fragment eine Laenge groesser 0 hat, muss es betrachtet

```

```

        werden
    if(fragment.length() > 0){
        List<String> fragmenteMitTeilstrings = new ArrayList<String>();

        for(String vergleichsFragment : uniqueFragmentListe){
            // Wenn Vergleichsfragment eine Teilstring beinhaltet merken
            if(vergleichsFragment.length() > 0 &&
                vergleichsFragment.contains(fragment)){
                fragmenteMitTeilstrings.add(vergleichsFragment);
            }
        }

        // Wenn es keine weiteren Fragmente mit Teilstrings gibt, dann zu
        // Teilstring-freien Liste hinzufuegen
        if(fragmenteMitTeilstrings.size() == 1){
            teilstringFreieListe.add(fragmenteMitTeilstrings.get(0));
        }
    }

    return teilstringFreieListe;
}
//</editor-fold>

//<editor-fold desc="Der Greedy-Substring-Algorithmus">
/**
 * Fuehrt den Greedy-Superstring-Algorithmus durch
 * @param fragmentListe Fragmentliste, die bearbeitet wird
 * @return Superstring
 */
private static String GreedySuperstring(List<String> fragmentListe){
    List<Integer> fragmentIndizes;

    // Laeuft solange mehrere Fragmente vorhanden sind
    while(fragmentListe.size() > 1){

        findeBesteDeckung(fragmentListe);

        String gemergetesFragment = mergeFragmente();

        // Loesche einzelfragmente
        fragmentListe.remove(fragment1);
        fragmentListe.remove(fragment2);

        // Fuege gemergetes, ganzes Fragment hinzu
        fragmentListe.add(gemergetesFragment);
    }

    return fragmentListe.get(0);
}

/**
 * Findet die beste Deckungsrate
 */

```

```
* @param fragmentListe Fragmentliste
*/
private static void findeBesteDeckung(List<String> fragmentListe){
    fragment1 = null;
    fragment2 = null;
    besteDeckung = 0;
    indexBesteDeckung = 0;

    for(String fragment : fragmentListe) {
        for (String vergleichsFragment : fragmentListe) {

            // Das gleiche Fragment darf nicht mit sich selbst verglichen
            // werden
            if (!fragment.equals(vergleichsFragment)) {
                int indexAktuelleDeckung = 0;
                int indexVergleichsFragment = 0;

                int aktuelleDeckung = 0;

                // Prueft jeden Buchstaben auf Ueberlappung
                for (int k = 0; k < fragment.length(); k++) {
                    if (fragment.charAt(k) ==
                        vergleichsFragment.charAt(indexVergleichsFragment)) {
                        // Nur der Start der Ueberlappung wird gespeichert
                        if(indexAktuelleDeckung == 0){
                            indexAktuelleDeckung = k;
                        }

                        aktuelleDeckung++;
                        indexVergleichsFragment++;
                    } else {
                        indexAktuelleDeckung = 0;
                        indexVergleichsFragment = 0;
                        aktuelleDeckung = 0;

                        //Da index von vergleichsFragment wieder auf 0 gesetzt
                        //ist, muss nochmal geprueft werden
                        if(fragment.charAt(k) ==
                            vergleichsFragment.charAt(indexVergleichsFragment)
                        ){
                            indexAktuelleDeckung = k;
                            aktuelleDeckung++;
                            indexVergleichsFragment++;
                        }
                    }
                }

                //Nur bessere Ueberlappungen merken
                if (aktuelleDeckung >= besteDeckung) {
                    besteDeckung = aktuelleDeckung;
                    indexBesteDeckung = indexAktuelleDeckung;

                    fragment1 = new String(fragment);
                    fragment2 = new String(vergleichsFragment);
                }
            }
        }
    }
}
```

```

    }
    }
}

/**
 * Merged das aktuelle Fragment mit dem optimalen Fragment
 *
 * @return Das gemergete Fragment
 */
private static String mergeFragmente(){
    String gemergetesFragment = null;

    if(besteDeckung != 0){
        int indexRest = ((fragment1.length() - 1) - indexBesteDeckung) + 1;
        gemergetesFragment = fragment1 + fragment2.substring(indexRest);
    } else {
        //System.out.println("Wir raten.");

        //Wenn keine Ueberlappung ermittelt wurde einfach mergen
        gemergetesFragment = fragment1 + fragment2;
    }

    return gemergetesFragment;
}
//</editor-fold>

//<editor-fold desc="Ausgabemethoden">
/**
 * Gibt einen Superstring aus.
 * @param superString Der Superstring der ausgegeben werden soll.
 */
private static void ausgabedesSuperstrings(String superString){
    System.out.println("Superstring: " + superString);
}
//</editor-fold>
}

```

## Aufgabe 1.2

### Ergebnis:

Das Wohltemperierte Klavier (BWV 846–893) ist eine Sammlung von Präludien und Fugen für ein Tasteninstrument von Johann Sebastian Bach in zwei Teilen. Teil I stellte Bach 1722, Teil II 1740/42 fertig. Jeder Teil enthält 24 Satzpaare aus je einem Präludium und einer Fuge in allen Dur- und Molltonarten, chromatisch aufsteigend angeordnet von C-Dur bis h-Moll. Mit dem Begriff Clavier, der alle damaligen Tasteninstrumente umfasste, ließ Bach die Wahl des Instruments für die Ausführung bewusst offen. Die Orgel scheidet in den meisten Fällen aus, da Bach keine separate Pedalstimme notierte oder als solche bezeichnete und die Orgeln seiner Zeit mitteltönig gestimmt waren. Der größte Teil des Werks ist offenbar für

Clavichord oder Cembalo konzipiert. Nach einer Äußerung Johann Nikolaus Forkels hatte Bach eine Vorliebe für das Clavichord. Im Nekrolog von 1754 steht dagegen über Bach: Die Clavicymbale wußte er, in der Stimmung, so rein und richtig zu temperiren, daß alle Tonarten schön und gefällig klangen. Das Werk wird heute sowohl auf dem Cembalo als auch auf dem modernen Klavier bzw. Flügel gespielt.

## Erkenntnis:

Die Lösung ist eindeutig, bei jedem Durchgang konnte ein Overlap ermittelt werden.

## Aufgabe 1.3

### Ergebnis:

```
TGCTTTCCATTTTGAATATTAATATGACAGGAAATATCAGATGGAAATATTGACATCTGTA
ATGTATGTCAATAAATGAATTCTAAGTTAGTAGAGTTTGATGATTTTTTTCTGTTCTCTAA
AAAAAGGAAGGGAGAAGAGAGGAAAAGATGTTTCAGGGAGCTACCATTTTGTCTTAGCT
GTGATTTTATAAAATGATAGACACTTTTATCTTTGTGTTACGTTCTACCCCCAGATGAG
AAAAGTGAAGTCAAAAAATACAAGTGACCCGTCCACAGGCAGATAGTTAGGAATTGGG
TTTTTATTCAGAAGGGAGGGGCAGGAGCCGTTTCCTGAAACCTCCTGCATAGGGCATT
TCGAGAGATTGCACCATCAAATAATATTAGTGATAAATAAGAAGGCAGGAAGAACTTTT
GGAGGTGATGGATAGGTTTATGGTATAGATTGTGGCCTGACTTACTTTAGTAATAAAATT
GTCCAAGGACTAAATTTATAGATAAGATACCTCTTTGTCTCCTTATTGACAGAGTGAATG
GGGCAACTGTGGTGGAAGAAATGTGTGTATGTATGAGTGTGTGATGGAGCTAACTTTTC
TACAATGTCTACTAACATGTCTTAGCCTTTACTTCATTGCGCTGTTTCCTTCTCACAAAAA
CCCTGTATGGGAGTTTTTCTTTACTTTTTATTTGAGACAAAGTCTCGCTCTGTCTCCCAG
GCTGGAGTGCAGTGGCGCTATATCGGCTCACTGCAGCCTCCACCTCCCGGGTTCAAGC
GATTCTCCTGCCTCAGCCTCCTGAGTAGCTGGTACTACAGGCGTGCACCACCATGCCA
CTATTTTTTTGTATTTTAGTAGCCAGGAGTTTTTCTTATACTCATTTTATTGAGAAGGGAG
GGGCAGGAGGGAATGACAAGTGACTCACCTTGAATTCTTCCTCTAAGAACTCACACCT
GAGCTTTGAGCTATAAAGAAATCTGATGCTGTTTCTGGGATCTGGAGAGGAAGACTCAG
TCCAGAATCCTCCCAGGGCCTTGAAAGTCCATCTCTGACCCAAAACAATCCAAGTAAGT
ACCTAATTCCTTTGGGAGTGGGTTGTGTATCTCACAGCAACAGAGAAAAAATAGTCACT
TAAAAGTTTCTCTTTGACATCTGTAATGTATGTCAATAAAAAAGAGAGAACTAAAAACA
AAAAGAAGCAGAAGCAAAAGTTAATGAGTCTTAACAGTTGCTTACCTATTGAAAACCTAT
TTAGAAATACTCTTTTAACATTGTGGTCACCTGAGTAAATCACTGGAGATAGTGCATTTT
AGAAATGTCTCCGTTCTGATTCCATAAACAATTTGACTTGTATAGTGTGCTATATTTTGGT
GATTTATCAAATCTTGATGTGAGTTTGGGAGTATTGCTAATGTCAGATGACTTGGGAAC
AAGAATAAGACATTTAACCTATGCTTAATTGAAATGAAATTTTTCCAGTGTATGCCTATC
CCCAGACTCTCTCCTCCTCCTCACCTCATTGTCTCCCCGACTTATCCTAATGCGAAGAA
ATCTGATGCTGTTTCTGGTGCTGTCTTAGAATCACTTCAGGAGTATTGACAAGAGGGGT
AGGAACCTTAGCGGGACCTGAACTTGAGGGCGGGTCTTTCTGACTCCAAAGCCTCTT
CCTGGCTACTCTGATATTGGCTATTGGCGGAGGCTGGGAAAACCTTGAAATGGGGAATG
TATACATGGAATATGTAAAGCTTTTATATGTCAGTCACACCTCAGTAAAGTGGTTTACCT
ATCTATCTATCTATCTATCTATCTATAATTTTTTTTTCTGTTCTGAGGATGTTGCAAC
AAATACTGATGCAACTCCTGGTTAACTGATAAAGTACTGGCCAGGGACAAAGCTCTCTT
```

GCAGCAATTTCCCACCACGTACCTCTGCCCTCTCCTCACAGCTGGAGAGGGAAAGTCA  
 TGAATCCTTGTCTTCCTCTTGTTTCCACCTCTTCAAGATTGGGCCAATTGCAATGGAA  
 TATCCATTGGTTGTGAGGCCTTTGTA CTCTGCAAGGAAAAGAAAAGAGACGGGGTTTCA  
 CTATGTTGGCCAGACTGGTCTCGA ACTCTTGACCTCAGGTGATCCGCCCCGCCTCGGCT  
 TCCCAGAGTGCTAGGATTACAGGCGTCCTGAGACCCTTCCTCCAGTCCTCCAAATTATG  
 GATCTGTGCCATTTGTACCGTGGACTTTTCTGTTTTCGCATTCCAGCCTGACAGGGGTG  
 ATTTGTAGCAAAATCGTGACTTCAGTTGTAAACTCTTCTATTATTATTATTTTTTTGAGACT  
 TTTTAAAAGATAGA

## Erkenntnis:

Ab den letzten 6 Fragmenten gibt es keine Overlaps mehr -> keine Eindeutige Lösung kann gefunden werden. (In unserem Algorithmus werden die letzten zwei betrachteten Fragmente gemerged).

## Aufgabe 1.4

### Ergebnis:

TTGACATCTGTAATGTATGTCAATAAATGAATTCTAAGTTAGTAGAGTTTGATGTAAAGTC  
 CTGAAAATTAAAAAGAGAGAAACTAAAAACAAAAGAAGCAGAAGCAAAAGTTAATGA  
 GTCTTAACAGTTGCTTACCTATTTGTAGCAAAATCGCTGGGATCTGGAGAGGAAGACTC  
 AGTCCAGAATCCTCCCAGGGCCTTGAAAGTCCATCTCTGACCCAAAACAATCCAAGTAA  
 GTACCTAATTCCTTTGGGAGTGGGTTGTGTATCTCACAGCAACAGAGAAAAAATAGTCA  
 CTTAAAAGTTTCTCTTTGACATCTGTAATGTATGTCAATAAAACAAAAGAAGCAGAAGC  
 AAAAGTTAATGAGTCTTAACAGTTGCTTACCTATTGAAAACCTATTTAGAAATACTCTTTT  
 AACATTGTGGTCACCTGAGTAAATCACTGGAGATAGTGCATTTTCAAGAAATGTCTCCGTT  
 CTGATTCCATAAACAATTTGACTTGTATAGTGTGCTATATTTTGGTGATTTATCAAATCTT  
 GATGTGAGTTTGGGAGTATTGCTAATGTCAGATGACTTGGGAACCTAAGAATAAGACATT  
 TAACCTATGCTTAATTGAAATGAAATTTTTCCCTAGAAGAAGAGTAGGTGGAAAAAGTCT  
 TCTTTCTTGACTTCAGTTGTAAACTCTTCTATTGCTTTCCATTTTGAATATTAATATGACA  
 GGAAATATCAGATGGAAATATTTTTAAAAGATAGAAATGTGAGTATGACGAAGAACTCTC  
 TCCTCCTCCTCACCTCATTGTCTCCCCGACTTATCCTAATGCGAAATTGGATATCTATCT  
 ATCTATCTATCTATCTATCTAAATTTTTTTTTCTGTTCTCTTGTCTCTGAGACCCTTCCTCA  
 AGATTTGCAGCAATTTCCCACCACGTACCTCTGCCCTCTCCTCACAGTGTATGCCTATC  
 CCCAGACTCATCAAAGTGTATACATGGAATATGTAAAGCTTTTATATGTCAGTCACACCT  
 CAGTAAAGTGGTTTACCTATCTATCTATCTATCTATCTATCTATCTAAGAAATGTGT  
 GTATGTATGAGTGTGTGATGGAGCTAACTTTTCTACAATGTCTACTAACATGTCCTAGCC  
 TTTACTTCATTGCGCTGTTTCCTTCTCACAAAAACCCTGTATGGGAGTTTTTCTTTACTTT  
 TTATTATTATTTTTTTGAGACAAAGTCTCGCTCTGTCTCCCAGGCTGGAGTGCAGTGGC  
 GCTATATCGGCTCACTGCAGCCTCCACCTCCCGGGTTCAAGCGATTCTCCTGCCTCAG  
 CCTCCTGAGTAGCTGGTACTACAGGCGTGACCACCATGCCACTATTTTTTTGTATTTTTA  
 GTAGAGACGGGGTTTCACTATGTTGGCCAGACTGGTCTCGA ACTCTTGACCTCAGGTG  
 ATCCGCCCCGCCTCGGCTTCCCAGAGTGCTAGGATTACAGGCGTGAGCCACTGCGCCC  
 AGCCAGGAGTTTTTCTTATACTCATTTTACAGATGAGAAAACCTGAGACTCAAAAAATACA  
 AGTGACCCGTCCACAGGCAGATAGTTAGGAAGTAGCGGGACCTGA ACTTGAGGGCGG

GTCTTTCTGACTCCAAAGCCTCTTCCTGGCTACTCTGATATTGGCTATTGGCGGAGGCT  
 GGGAAACTTGAAATGGGGAATGATCGGGGAGCGGGCGAGGGGGGACCAGCCGTTAAG  
 CATTCCAGCCTGACAGGGGTGATTTGTTAAACCCAGGAAGTAGTTAGACGTTTCCTGAA  
 ACCTCCTGCATAGGGCATTTTCGAGAGATTGCACCATCACCCAGTCCTCCAAATTATGG  
 ATCTGTGCCATTTGTACCGTGGACTTTTCTGTTTTCTGAGGATGTTGCAACAAATACTGA  
 TGCAACTCCTGGTTAACTGATAAAGTACTGGCCAGGGACAAAGCTCTCTTGACGAATT  
 TCCCACCACGTACCTCTGCCCTCTCCTCACAGCTGGAGAGGGAAAGTCATGGAATCCT  
 TGTCCCTTCTCTTGTTCACCTCTTCAAGATTGGGCCAATTGCAATGGAATATCCATTG  
 GTTGTGAGGCCTTTGTACTCTGCAAGGAAAAGAAAAGAAATGTGTGTATGTATGAGTGT  
 GTTTTTCTGTTCTAAAAAAGGAAGGGAGAAGAGAGGAAAAGATGTTTCAGGGAGCTAC  
 CATTTTGTCTAGCTGTGATTTTATAAAATGATAGACACTTTTATCTTTGTGTTACGTTT  
 CTACCCCCAGTTATTCAGAAGGGAGGGGCAGGAGGGAATGACAAGTGAATCACCTTGA  
 ATTCTTCCTCTAAGAACTCACACCTGAGCTTTGAGCTATAAAGAAATCTGATGCTGTTT  
 CTGGTGCTGTCTTAGAATCACTTCAGGAGTATTGACAAGAGGGGTAGGAACCCTTAGAA  
 ATAATATTAGTGATAAATAAGAAGGCAGGAAGAACTTTTGGAGGTGATGGATAGGTTTA  
 TGGTATAGATTGTGGTGATGATTTAATGATTAAAAGATAGAAATGTGAGTATGACGAAGA  
 ACTTTAGTAATAAAATTGTCCAAGGACTAAATTTATAGATAAGATACCTCTTTGTCTCCTT  
 ATTGACAGAGTGAATGGGGCAACTGTGGAGCCTGACTTACTTCTTTTAATTGGGTTTTTA  
 TTCAGAAGGGAGGGGCAGGAGGGAATGTTTTTTTTCTGTTCTAAAAAAGGAAGG

### Erkenntnis:

Ab den letzten 5 Fragmenten gibt es keine Overlaps mehr -> keine Eindeutige Lösung kann gefunden werden. (In unserem Algorithmus werden die letzten zwei betrachteten Fragmente gemerged).

## Aufgabe 1.5

### Ergebnis:

TATCTATCTATCTATCTATCTATCTAAATTTTTTTTTCTGTTCTTGCAGCAATTTCC  
 CACCACGTACCTCTGCCCTCTCCTCACAGCTGGAGAGGGAAAGTCATGGAATCCTTGT  
 CTTTCTCTTGTTCACCTCTTCAAGATTGGGCCAATTGCAATGGAATATCCATTGGTT  
 GTGAGGCCTTTGTACTCTGCAAGGAAAAGAAAAGAAATGTGTGTATGTATGAGTGTGTG  
 ATGGAGCTAACTTTTCTACAATGTTATTCAGAAGGGAGGGGCAGGAGGGAATGACAAGT  
 GACTCACCTTGAATTCTTCCTCTAAGAACTCACACCTGAGCTTTGAGCTATAAAGAAAT  
 CTGATGCTGTTTCTGGTGCTGTCTTAGAATCACTTCAGGAGTATTGACAAGAGGGGTAG  
 GAACCCTTAGAAATAATATTAGTGATAAATAAGAAGGCAGGAAGAACTTTTGGAGGTG  
 ATGGATAGGTTTATGGTATAGATTGTGGTGATGATTTAATGAGTGTATGCCTATCCCCAG  
 ACTCATCAAAGTGTATACATGGAATATGTAAAGCTTTTATATGTCAGTCACACCTCAGTA  
 AAGTGGTTTACCTATCTATCTATCTATCTATCTATCTATCTAAATTTTTTTTTCTGTT  
 CCTAAAAAAGGAAGGGAGAAGAGAGGAAAAGATTAGTAATAAAATTGTCCAAGGACTA  
 AATTTATAGATAAGATACCTCTTTGTCTCCTTATTGACAGAGTGAATGGGGCAACTGTGG  
 AGCCTGACTTACTTCTTTAATTGGGTTTTTATTGACAAGGGAGGGGCAGGAGGGAATG  
 ACAAGAGTAGGTGGAAAAAGTCTTCTTTCTTGACTTCAGTTGTAACTCTTCTATTGCTT  
 TCCATTTTGAATATTAATATGACAGGAAATATCAGATGGAAATATTTTAAAAGATAGAAA



TGTGAGTATGACGAAGAACTCTCTCCTCCTCCTCACCTCATTGTCTCCCCGACTTATCCT  
AATGCGAAATTGGATTCTGAGCATTGTAGCAAAATCGCTGGGATCTGGAGAGGAAGAC  
TCAGTCCAGAATCCTCCCAGGGCCTTGAAAGTCCATCTCTGACCCAAAACAATCCAAGT  
AAGTACCTAATTCTTTGGGAGTGGGTTGTGTATCTCACAGCAACAGAGAAAAAATAGT  
CACTTAAAAGTTTCTCTTTGACATCTGTAATGTATGTCAATAAATGAATTCTAAGTTAGTA  
GAGTTTGATGTAAAGTCCTGAAAATTAAGAGAGAACTAAAAACAAAAAGAAGCA  
GAAGCAAAAGTTAATGAGTCTTAACAGTTGCTTACCTATTAAAAGATAGAAATGTGAGTA  
TGACGAAGAACTTTAGTAATAAAATTGTCCAAGGACTAAATTTATAGATAAGAAATGTGT  
GTATGTATGAGTGTGTGATGGAGCTAACTTTTCTACAATGTCTACTAACATGTCCTAGCC  
TTTACTTCATTGCGCTGTTTCCTTCTCACAAAAACCCTGTATGGGAGTTTTTCTTTACTTT  
TTATTATTATTTTTTTGAGACAAAGTCTCGCTCTGTCTCCCAGGCTGGAGTGCAGTGGC  
GCTATATCGGCTCACTGCAGCCTCCACCTCCCGGGTTCAAGCGATTCTCCTGCCTCAG  
CCTCCTGAGTAGCTGGTACTACAGGCGTGACCACCATGCCACTATTTTTTTGTATTTTTA  
GTAGAGACGGGGTTTCACTATGTTGGCCAGACTGGTCTCGAACTCTTGACCTCAGGTG  
ATCCGCCCCGCTCGGCTTCCCAGAGTGCTAGGATTACAGGCGTGAGCCACTGCGCCC  
AGCCAGGAGTTTTTCTTATACTCATTTTACAGATGAGAAAACCTGAGACTCAAAAAATACA  
AGTGACCCGTCCACAGGCAGATAGTTAGGAAGTAGCGGGACCTGAACTTGAGGGCGG  
GTCTTTCTGACTCCAAAGCCTCTTCCTGGCTACTCTGATATTGGCTATTGGCGGAGGCT  
GGGAAAACCTGAAATGGGGAATGATCGGGGAGCGGCGAGGGGGGACCAGCCGTTAAG  
CATTCCAGCCTGACAGGGGTGATTTGTTAAACCCAGGAAGTAGTTAGACGTTTCCTGAA  
ACCTCCTGCATAGGGCATTTTTCGAGAGATTGCACCATCAAAACAAAAAGAAGCAGAAGC  
AAAAGTTAATGAGTCTTAACAGTTGCTTACCTATTGAAAACCTATTTAGAAATACTCTTTT  
AACATTGTGGTCACCTGAGTAAATCACTGGAGATAGTGCAATTCAGAAATGTCTCCGTT  
CTGATTCCATAAACAATTTGACTTGTATAGTGTGCTATATTTTGGTGATTTATCAAATCTT  
GATGTGAGTTTGGGAGTATTGCTAATGTCAGATGACTTGGAAGTAAGAATAAGACATT  
TAACCTATGCTTAATTGAAATGAAATTTTTTCCCTAGAAGAAGAGTAGGTGGAAAAAGTCT  
TCTTTCTTGACTTCAGTTTTCTGTTCTAAAAAAGGAAGGGAGAAGAGAGGAAAAAGAT  
GTTCAAGGAGCTACCATTTTGTCTAGCTGTGATTTTATAAAATGATAGACACTTTTATC  
TTTGTGTTACGTTCTACCCCCAGTCCTCCAAATTATGGATCTGTGCCATTTGTACCGTG  
GACTTTTCTGTTTTCTGAGGATGTTGCAACAAATACTGTTGTACCGTGGACTTTTCTGTT  
TTCTGAGGATGTTGCAACAAATACTGATGCAACTCCTGGTTAACTGATAAAGTACTGGC  
CAGGGACAAAGCTCTTGTCTGAGACCCTTCCTCAAGATTTGCAGCAATTTCCCACC  
ACGTACCTCTGCCCTCTCCTCACAGTTTATTGAGAAGGGAGGGGCAGGAGGGAATGAC  
AAGTGACTATCTATCTATCTATCTATCTAAATTTTTTTTTCTGTTCTAAAAAAG

## Erkenntnis:

Ab den letzten 6 Fragmenten gibt es keine Overlaps mehr -> keine Eindeutige Lösung kann gefunden werden. (In unserem Algorithmus werden die letzten zwei betrachteten Fragmente gemerged).

# Aufgabe 2

## Aufgabe 2.1

```
package uebung2.aufgabe2;

import net.gumbix.dynpro.DynProJava;
import net.gumbix.dynpro.Idx;
import net.gumbix.dynpro.PathEntry;
import scala.Function2;
import scala.Option;
import scala.Some;
import scala.collection.concurrent.Debug;

import java.util.Arrays;
import java.util.List;

/**
 * Created by Dennis on 29.11.2017.
 */
public class GlobalAlignment extends net.gumbix.dynpro.DynProJava<Integer> {

    //Nucleotid Sequences
    private String[] s = (" CGATCCTGT").split("");
    private String[] t = (" CATCGCCTT").split("");

    public static void main(String[] args) {

        GlobalAlignment ga = new GlobalAlignment();

        List<PathEntry<Integer>> solutionJava = ga.solutionAsList(new
Idx(ga.n() - 1, ga.m() - 1));
        System.out.println("Optimal Decisions:");
        for (PathEntry<Integer> entry : solutionJava) {
            System.out.print(entry.decision() + " ");
        }

        System.out.println("\n");
        System.out.println(ga.mkMatrixString(ga.solution(new Idx(ga.n() - 1,
ga.m() - 1))));
    }

    //TODO check why values of diagonal (idx.i() = idx.j()) are wrong
    @Override
    public Object decisions(Idc idx) {
        //Start
        if (idx.i() == 0 && idx.j() == 0) {
            System.out.println(idx.i() + " " + idx.j() + " START");
        }
    }
}
```

```

        return new Integer[]{0};
        //Insertion
    } else if (idx.i() == 0 && idx.j() > 0) {
        System.out.println(idx.i() + " " + idx.j() + " INSERT");
        return new Integer[]{1};
        //Deletion
    } else if (idx.j() == 0 && idx.i() > 0) {
        System.out.println(idx.i() + " " + idx.j() + " DELETION");
        return new Integer[]{2};
        //1 Match, -1 Mismatch
    } else {
        System.out.println(idx.i() + " " + idx.j() + " INSERT, DELETION,
BOTH");

        //TODO Check...
        return new Integer[]{1,2,3};
    }
}

//should be correct, just like on the slides "BIM-40" page 18
@Override
public Idx[] prevStates(Idx idx, Integer d) {

    //1 for Insert
    if(d == 1){
        return new Idx[]{new Idx(idx.i(), idx.j() - 1)};
        //2 for Deletion
    } else if(d == 2){
        return new Idx[]{new Idx(idx.i() - 1, idx.j())};
        //3 for Both
    } else if (d == 3){
        return new Idx[]{new Idx(idx.i() - 1, idx.j() - 1)};
        //0 for Start
    } else {
        return new Idx[]{};
    }
}

@Override
public double value(Idx idx, Integer d) {

    //Start
    if (d == 0) {
        return 0;
        //Insert or Deletion
    } else if (d == 1 || d == 2) {
        return -2;
        //Both
    } else {
        return similarity(s[idx.i()], t[idx.j()]);
    }
}
}

```

```
/**
 * checks if sequences at given index is a match or a mismatch
 *
 * @param s    sequence s
 * @param t    sequence t
 * @return 1 for match, -1 for mismatch
 */
private int similarity(String s, String t) {
    if (s.equals(t)) {
        return 1;
    } else {
        return -1;
    }
}

@Override
public int n() {
    return s.length;
}

@Override
public int m() {
    return t.length;
}

@Override
public Function2 extremeFunction() {
    return this.MAX();
}

@Override
public String[] rowLabels() {
    return s;
}

@Override
public Option<String[]> columnLabels() {
    String[] cArray = new String[t.length];
    for (int i = 0; i < t.length; i++) {
        cArray[i] = "" + t[i];
    }
    return new Some(cArray);
}
}
```

## Aufgabe 2.2

### Global Alignment (Needleman-Wunsch):

```
>> [Score2, Alignment2] = nwalgn(aminoT, aminoS, 'Alphabet', 'AA', 'ScoringMatrix', aminoscore, 'GapOpen', 2);
>> Score2

Score2 =

    -16

>> Alignment2

Alignment2 =

    3×28 char array

    'KAQYRRE-----CMI---FVWEI-NRL'
    '| ||| ||         |   |||  |'
    'KIQYKREFNIPSVSLINSLFAWEIRDRI'
```

```
>> [Score1, Alignment1] = nwalgn(seqT, seqS, 'Alphabet', 'NT', 'ScoringMatrix', scorematrix, 'GapOpen', 2);
>> Score1

Score1 =

     0

>> Alignment1

Alignment1 =

    3×10 char array

    'C-ATCGCCTT'
    '| ||| |  |'
    'CGATC-CTGT'
```

### Local Alignment (Smith/Waterman):

```
>> [Score1, Alignment1] = swalign(seqT, seqS, 'Alphabet', 'NT', 'ScoringMatrix', scorematrix, 'GapOpen', 2);
>> Score1

Score1 =

     3

>> Alignment1

Alignment1 =

    3×3 char array

    'ATC'
    '|||'
    'ATC'
```

```
>> [Score2, Alignment2] = swalign(aminoT, aminoS, 'Alphabet','AA','ScoringMatrix', aminoscore, 'GapOpen', 2);
>> Score2

Score2 =

     3

>> Alignment2

Alignment2 =

3×7 char array

'KAQYRRE'
'| || ||'
'KIQYKRE'
```

## Aufgabe 2.3

### Local Alignment (Smith/Waterman):

```
>> [Score3, Alignment3] = swalign(aminoT, aminoS, 'Alphabet','AA','ScoringMatrix', 'Blosum62', 'GapOpen', 5);
>> Score3

Score3 =

    15.5000

>> Alignment3

Alignment3 =

3×19 char array

'KAQYRRECMI-FVWEINRL'
'| ||:|| | | || |'
'KIQYKREPNI PSVSLINSL'
```

### Global Alignment (Needleman-Wunsch):

```
>> [Score3, Alignment3] = nwalignment(aminoT, aminoS, 'Alphabet','AA','ScoringMatrix', 'Blosum62', 'GapOpen', 5);
>> Score3

Score3 =

     8.5000

>> Alignment3

Alignment3 =

3×28 char array

'KAQYRRE-----CMI---FVWEI-NRL'
'| ||:||           :|   |:||| :|:'
'KIQYKREPNI PSVSLINSLFAWEIRDRI'
```

Gap Penalty 5: bestes Ergebnis für lokales Alignment, da die Sequenz nicht in verschiedene kleine Einzelteile zerlegt wird. Für Globales Alignment spielt es in diesem Fall keine Rolle, da immer auf die gesamte Sequenz ausgerichtet wird. Bei kurzen Sequenzen gibt es kaum andere Möglichkeiten für Alignments.

Das lokale Alignment ist mit Hilfe der Blosom62 Matrix effektiver, als mit der selbst erstellen Scoringmatrix in Aufgabe 2.2

# Aufgabe 3

## Aufgabe 3.1

		s1	s2	s3	s4	
		GCTTATA	GCTATA	GTTATA	GCTTAGA	$\Sigma$
s1	GCTTATA	7	4	4	5	20
s2	GCTATA	4	6	4	2	16
s3	GTTATA	4	4	6	2	16
s4	GCTTAGA	5	2	2	7	16

Zentrum  $c = s1$

Blätter  $B = \{s2, s3, s4\}$

MA1 ( $c$  und  $s2$ ):

GCTTATA  
 || ||||  
 GC-TATA

-----

A ( $c$  und  $s3$ ):

GCTTATA  
 | |||||  
 G-TTATA

MA2:

GCTTATA  
 GC-TATA  
 G-TTATA

-----

A ( $c$  und  $s4$ ):

GCTTATA  
 ||||| |  
 GCTTAGA



MA3 (finales Alignment):

GCTTATA

GC-TATA

G-TTATA

GCTTAGA

-----

GCTTATA (Consensus-Sequenz)

Summe der Paare Bewertung =  $6 + (-3) + (-3) + 6 + 6 + 0 + 6 = 18$

Consensus Bewertung = 3

## Aufgabe 3.2

MATLAB code:

```
s1 = 'GCTTATA';
```

```
s2 = 'GCTATA';
```

```
s3 = 'GTTATA';
```

```
s4 = 'GCTTAGA';
```

```
scorematrix = eye(4);
```

```
scorematrix(scorematrix==0) = -1;
```

```
S = {s1,s2,s3,s4};
```

```
output = multialign(S, 'ScoringMatrix', scorematrix, 'GapOpen', 2);
```

```
seqalignviewer(output)
```




Abbildung 5: Sequence Align Viewer Output